

Del Volumen al 2.5D

Segmentación de Tumores Pulmonares con Vision Transformers Slice-wise

Francisco Javier Mercader Martínez Chaimae Chahlal Hiba Chakour

5 de mayo de 2026


Índice

1. Motivación y objetivo
2. Datos: MSD Task06_Lung
3. Preprocesamiento
4. Arquitectura **ViT25D**
5. Pérdida y entrenamiento
6. Inferencia volumétrica
7. Fase 6: ablación
8. Resultados
9. Discusión y conclusiones


Motivación y objetivo

¿Por qué segmentar tumores pulmonares en CT?

- Tarea clave en diagnóstico, planificación radioterápica y seguimiento.
- La delimitación manual es **lenta** y depende del especialista.
- Variabilidad inter-observador $\Rightarrow$ necesidad de automatización.
- Formulación natural: problema **3D** sobre (H, W, D) .




El problema de las redes 3D



Pregunta del proyecto: ¿puede una arquitectura 2D pre-entrenada comportarse como un segmentador volumétrico si se le da contexto local en profundidad?

Alcance del proyecto




Reorientamos el proyecto a una **línea principal compacta**: segmentación + ablación. Task06 no tiene etiquetas B/M, así que la clasificación queda fuera.


Datos

MSD Task06_Lung

- CT torácicos en **NIfTI** + máscaras binarias ([Antonelli et al. 2022](#); [Simpson et al. 2019](#)).
- **63 casos anotados** + 32 test sin máscara pública.
- Heterogeneidad: tamaño, forma, localización, spacing.
- Toda la validación se hace sobre los 63 anotados.



Particiones sin fugas




- **Grupo:** `patient_id` $\Rightarrow$ ningún paciente cae en train y val.
- **Estratificación:** terciles de volumen tumoral.

⚠ Advertencia

Partir por cortes 2D filtraría contexto anatómico $\rightarrow$ métrica artificialmente inflada.

Preprocesamiento


Pipeline de preprocesado



Spacing fijo $\Rightarrow$ **5 cortes vecinos** equivalen a una distancia anatómica estable entre pacientes.


Máscara pulmonar como prior anatómico

- Pre-cómputo con [lungmask R231](#) ([Hofmanninger et al. 2020](#)).
- Vóxeles fuera de pulmón → **-1024 HU**.
- El modelo **no malgasta capacidad** descartando regiones extra-pulmonares.
- Estabiliza también [CropForegroundd](#).



Tres ventanas HU como canales


Canal	Rango HU	Para qué
Pulmón	$[-1000, 0]$	Parénquima, bordes lesión-pulmón
Mediastino	$[-150, 250]$	Tejidos blandos, tumor sólido
Completa	$[-1024, 400]$	Contexto anatómico global



Ventanas tras el crop $\Rightarrow$ caché ligera, no triplica RAM.

Ventanas HU sobre un corte real

Ventanas HU multicanal — cada canal ilumina un tejido distinto



Mismo corte axial, tres normalizaciones HU + sus histogramas.

- **Pulmón** ($[-1000, 0]$): parénquima y bordes lesión-pulmón.
- **Mediastino** ($[-150, 250]$): tumor sólido y tejidos blandos.
- **Completa** ($[-1024, 400]$): contexto anatómico global.

Cada ventana selecciona una franja distinta del histograma → apilarlas evita que el modelo tenga que aprender a comprimir el rango HU.

Muestreo y aumentación

Muestreo

- `RandCropByPosNegLabeld`
- Parche **96×96×16**
- Ratio **pos:neg = 3:1**
- El tumor ocupa muy poco volumen $\Rightarrow$ sin sesgo, los lotes serían casi todo fondo.

Aumentación **standard**


- Ruido gaussiano
- Suavizado
- Cambios intensidad/escala
- Rotaciones de 90°
- Flip **solo en Z**

⚠ Importante

⛔ `RandFlipd(spatial_axis=0)` **prohibido** — invertir L $\leftrightarrow$ R rompe convenciones anatómicas.


Arquitectura ViT25D

La idea: 3D como secuencia de 2D + contexto local



El eje **Z** entra como **batch interno**: ningún Conv3D, pero cada corte ve a sus vecinos.


Neighbor stacking visualmente



- $\text{neighbor_context} = 2 \Rightarrow$ **5 cortes** con **3 ventanas HU = 15 canales**.
- **Padding por replicación** en los bordes (no ceros artificiales).

Neighbor stacking — vista esquemática

Neighbor Stacking — el eje Z se procesa como contexto local



En los bordes del volumen: padding por replicación · no se introducen ceros artificiales

Para predecir el corte z se apilan sus vecinos $z \pm 2$ y se procesan como un único tensor 2D.

El contexto axial entra **por la entrada del modelo**, no se infiere a posteriori. Cada predicción nace ya con información de profundidad sin pagar el coste de un Conv3D.

Encoder ViT pre-entrenado


`vit_base_patch16_224.mae` vía `timm` (Wightman 2019), pre-entrenado con MAE (He et al. 2022).

Problema: ViT espera 3 canales RGB, nosotros tenemos 15.



Se preserva la **distribución inicial de activaciones** y el conocimiento pre-entrenado del primer kernel.

Pesos del primer Conv: cómo se preserva el MAE




El factor 3/15 conserva la magnitud de activación esperada por las capas posteriores · Reinicializar destruiría la inicialización MAE

Pesos RGB pre-entrenados → promedio de canales → replicación a 15 canales escalada por 3/15.

Reinicializar el `patch_embed` desde aleatorio destruiría la inicialización MAE.

Promediar y replicar conserva los detectores de bordes y orientaciones ya aprendidos; el factor 3/15 mantiene la varianza de activación esperada por las capas posteriores.

Decoder y supervisión profunda




- Tres bloques: $4\times \cdot 2\times \cdot 2\times = 16\times$ (compatible con patch size 16).
- Cabezas auxiliares en resoluciones intermedias.
- Pérdida total ponderada:

$$\mathcal{L} = 1.0 \mathcal{L}_1 + 0.5 \mathcal{L}_{1/2} + 0.25 \mathcal{L}_{1/4}$$

- La etiqueta se reduce **solo en XY**, el eje Z se conserva.

Congelación del encoder



Por defecto solo entrenan **decoder + cabezas**. Esto reduce VRAM, acelera y evita destruir representaciones útiles con pocos datos.

Si se descongela, el LR del encoder se reduce con `UNFREEZE_LR_FACTOR` (típicamente 0.1).

Pérdida y entrenamiento

Focal Tversky Loss

La segmentación tumoral está **muy desbalanceada** ([Abraham y Khan 2019](#)):

$$TI(P, G) = \frac{TP + \epsilon}{TP + \alpha FP + \beta FN + \epsilon}, \quad FTL = (1 - TI)^\gamma$$

Configuración activa


- $\alpha = 0.3$, $\beta = 0.7 \rightarrow$ penaliza más **falsos negativos**
- $\gamma = 4/3 \rightarrow$ exponente focal hacia regiones difíciles
- `include_background = false`

Por qué $\beta > \alpha$

En oncología, **perder parte de una lesión** suele ser peor que sobredelimitar el borde.

El exponente focal desplaza atención hacia bordes irregulares y zonas con densidad parecida al tumor.

Paisaje de la pérdida Focal Tversky




Configuración simétrica $\alpha = \beta = 0.5$, $\gamma = 1$ ($\approx$ Dice loss) vs configuración clínica activa $\alpha = 0.3$, $\beta = 0.7$, $\gamma = 4/3$.

A igualdad de magnitud de error, **perder tumor (FN) cuesta más que sobredelimitarlo (FP)**: la pendiente del paisaje es más pronunciada en el eje FN. El exponente focal $\gamma > 1$ inclina aún más la pérdida hacia las zonas difíciles.


Configuración de entrenamiento (**local_5060**)

Parámetro	Valor
Patch	96×96×16
Batch size	1
Grad accumulation	8
Optimizer	AdamW
LR	4e - 4
Scheduler	Cosine + warmup
Warmup steps	100
AMP	✓
Encoder chunk size	32



Acumulación de gradiente compensa el batch físico pequeño.

Validación por volumen completo



Entrenar y medir en parches puede ocultar errores de continuidad o componentes falsos lejos del crop. Por eso validamos sobre el volumen entero.

Métricas: Dice + HD95

Dice de foreground

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|}$$

Mide solapamiento volumétrico.

HD95

Distancia Hausdorff al **percentil 95**.


Más robusta que Hausdorff máxima ante outliers, captura calidad de **bordes**.

Dos máscaras pueden tener Dice parecido pero HD95 muy distinto. Monitorizar ambas evita lecturas incompletas.


Dice y HD95 no miden lo mismo

Dos errores con Dice casi idéntico, HD95 muy distinto

Predicción A — error compacto cerca del tumor



Predicción B — mismo overlap + FP distante



Dice = 0.945 ($\approx$ idéntico)
HD95 = 1.6 mm

TP (correcto) FN (tumor perdido)

Dice = 0.938 ($\approx$ idéntico)
HD95 = 61.0 mm

FP (predicho de más) Borde GT

HD95 calculado con spacing in-plane 0.79 mm · Dice mide overlap volumétrico, HD95 captura calidad de bordes y FP lejanos

Dice $\approx$ idéntico, HD95 muy distinto: un FP distante penaliza el borde.

- **A:** error pegado al tumor $\rightarrow$ Dice 0.945, HD95 = **1.6 mm**.
- **B:** mismo overlap pero un FP lejano $\rightarrow$ Dice 0.938, HD95 = **61 mm**.

Por eso reportamos siempre las dos métricas a la vez.


Checkpoints ligeros



Reducción de **>25×** en disco cuando el encoder permanece congelado.

Inferencia volumétrica

Sliding window slice-wise




Por qué no deslizar en Z: romper el contexto axial impediría construir los vecinos de cada corte.

Sliding window XY + chunking en Z (vista)


Inferencia volumétrica — sliding sólo en XY + chunking del encoder en Z

1. Sliding window en XY



Vista superior (eje Z hacia el lector)
La ventana se desplaza solo en XY · el eje Z permanece íntegro

2. Chunking del encoder en Z



Equivalente numérico al pase entero · acota la VRAM máxima


Romper el contexto axial impediría construir los vecinos del corte z · El chunking acota la VRAM sin alterar el resultado

La ventana se desplaza solo en XY; el eje Z se preserva íntegro y se trocea en chunks de 32 cortes.

Si deslizásemos también en Z, los cortes de los bordes de cada ventana no tendrían vecinos suficientes. El chunking del encoder acota la VRAM **sin alterar el resultado numérico** del forward.


Chunking del encoder

- Un volumen puede tener ~200 cortes.
- Pasar todos como batch interno por ViT-Base $\Rightarrow$ saturación VRAM.
- Trocear en chunks de 32 **no cambia el resultado numérico**, solo limita la memoria máxima.



Fase 6: ablación

Diseño experimental



Iteraciones fijas por celda y reducción **estratificada por terciles de volumen tumoral**.

Tendencias observadas


- 100 % de los datos: **standard** > **none** en mediana Dice y reduce HD95.
- 50 %: mismo patrón con menor margen.
- 25 %: mediana Dice similar; HD95 mejora con aumentación → **bordes más estables**.

Nota

Con 3 semillas el **Wilcoxon** tiene poca potencia: p no significativo $\neq$ ausencia de efecto.

Lectura: tendencias y estabilidad, no conclusión estadística fuerte.


Distribución del Dice



Dice por fracción de datos × régimen de aumentación.

Resultados

Curvas de entrenamiento




Focal Tversky, Dice y HD95 a lo largo del entrenamiento.

Monitorizar Dice y HD95: dos máscaras pueden tener Dice parecido y bordes muy distintos.


Visualización triplanar

Segmentación ViT25D — Mejor checkpoint (fold 0)


Axial (Slice 124)



Coronal (Slice 267)




Sagital (Slice 238)



Predicción vs ground truth en axial / coronal / sagital.

Útil para detectar **discontinuidades**, **fugas a mediastino** y desplazamientos respecto al tumor.

Mosaico axial




Cortes axiales consecutivos alrededor de la lesión.

Criterio visual: la máscara debe **crecer y decrecer suavemente en Z** (efecto del neighbor stacking).

Ingeniería y reproducibilidad

Estructura del paquete




Configuración separada de código $\Rightarrow$ se puede cambiar hardware, modelo o experimento sin tocar `src/`.

Tests críticos

Test	Qué protege
<code>test_vit_25d.py</code>	Shapes, deep supervision, congelación, adaptación de pesos, equivalencia chunking
<code>test_neighbor_stack.py</code>	Construcción de vecinos y padding por replicación
<code>test_multi_window.py</code>	Ventanas HU, no mutación de <code>MetaTensor</code>
<code>test_transforms.py</code>	Orden de transforms, prohibición flip L-R
<code>test_lung_mask_transform.py</code>	Aplicación máscara, errores claros si falta caché
<code>test_splits.py</code>	Sin solapamiento de pacientes, determinismo

Discusión

Lo que aporta el 2.5D



Compromiso razonable entre **contexto volumétrico** y **coste computacional**, alineado con datasets pequeños como Task06.

Limitaciones

- Contexto en **Z** es **local**: dependencias largas se capturan solo de forma indirecta.
- El **prior pulmonar** puede ser contraproducente si el tumor invade regiones que **lungmask** excluye.
- 63 casos $\Rightarrow$ **alta incertidumbre**; hay que reportar por fold y semilla.
- Métricas globales **no capturan todos los errores clínicos** (un FN pequeño en borde puede importar mucho).
- Sin baseline 3D fuerte (**nnU-Net** ([Isensee et al. 2021](#))) bajo el mismo protocolo.

Validez bajo restricciones de hardware

Restricciones GPU 8 GB

- Parche reducido
- Batch efectivo modesto
- Menos iteraciones
- 3 semillas
- Exploración de hiperparámetros limitada
- Encoder congelado por defecto
- Checkpoints parciales


Lectura prudente

Los resultados actuales **no son el techo de la arquitectura**, sino una evaluación inicial bajo condiciones ajustadas.

La infraestructura está lista para sustituir artefactos por **ejecuciones completas** cuando haya cómputo.

Conclusiones

Cinco ideas que se llevan



Segmentador 2.5D basado en **ViT pre-entrenado** integrado en un flujo MONAI reproducible, con tests sobre los contratos críticos.

Trabajo futuro

- Validación **multi-fold completa** + intervalos por bootstrap.
- **Baseline nnU-Net** bajo el mismo protocolo.
- Postprocesado por **componentes conectados**.
- Estudio de **descongelado parcial** del encoder.
- Más semillas y exploración de hiperparámetros con mejor hardware.

¡Gracias!

Repositorio: [Proyecto_MONAI](#)

Francisco Javier Mercader · Chaimae Chahlal · Hiba Chakour

Bibliografía

- Abraham, Nabila, y Naimul M Khan. 2019. «A Novel Focal Tversky Loss Function with Improved Attention U-Net for Lesion Segmentation». En *2019 IEEE 16th International Symposium on Biomedical Imaging (ISBI)*, 683-87. IEEE.
- Antonelli, Michela, Annika Reinke, Spyridon Bakas, et al. 2022. «The Medical Segmentation Decathlon». *Nature Communications* 13: 4128.
<https://doi.org/10.1038/s41467-022-30695-9>.
- He, Kaiming, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, y Ross Girshick. 2022. «Masked Autoencoders Are Scalable Vision Learners». En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 16000-16009.
- Hofmanninger, Johannes et al. 2020. «Automatic lung segmentation in routine imaging is a solved problem». *arXiv:2001.11767*.
- Isensee, Fabian et al. 2021. «nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation». *Nature Methods* 18: 203-11.
- Simpson, Amber L et al. 2019. «A large annotated medical image dataset for the development and evaluation of segmentation algorithms». *arXiv:1902.09063*.
- Wightman, Ross. 2019. «PyTorch Image Models». *GitHub repository*.